

GraphRAG深度剖析与二次开发

西瓜老师

📖 目录

- 1 GraphRAG 深度剖析之原理&快速实践
- 2 GraphRAG 深度剖析之 Index 流程详解
- 3 GraphRAG 深度剖析之 Query 流程详解
- 4 GraphRAG 深度剖析之源码二次开发优化

1 GraphRAG 深度剖析之原理&快速实践

01、经典RAG流程回顾

● 难度大 ● 难度小

数据工程




PDF数据
表格数据
HTML数据
等

1. 文件解析



2. 文件切割



3. 向量化



4. 知识入库



RAG

5. query 提问



6. 知识检索

9. 生成




8. 增强



7. 重排序



02、经典RAG流程回顾



03、经典RAG痛点

问题：去年技术团队的成果是什么？




问题宏观，
跨文档查询

RAG + 向量数据库



RAG + 知识图谱

04、什么是知识图谱?



1. 是一个存储信息的方法

2. 描述的是事实

3. 核心表达是实体和关系

4. 可以有多种实体，多种关系

05、GraphRAG 产品对比

编号	项目名	特色	开源地址	Star数
1	Microsoft GraphRAG	一个能够将知识图谱和 RAG 结合起来的数据 workflow 和转换工具，可以提供数据处理，检索问答能力，目前实测准确率最好，不过成本高，社区搜索速度慢。	https://github.com/microsoft/graphrag	24.7K
2	LightRAG	一个轻量级的RAG框架，支持图增强文本索引、增量更新算法等，比 Microsoft GraphRAG 更适合个人使用，成本相对较低。	https://github.com/HKUDS/LightRAG	15.5k
3	Fast-GraphRAG	更低延迟的GraphRAG实现，动态数据生成和增量更新等，成本约为Microsoft GraphRAG的1/6。	https://github.com/circlemind-ai/fast-graphrag	3.2k

06、GraphRAG 环境部署

核心步骤	操作命令
1.创建虚拟环境	conda create --name graphrag python=3.11 conda activate graphrag
2.安装依赖	pip install graphrag pip show graphrag
3.命令测试	graphrag --help

init

初始化GraphRAG 的配置文件;

index

构建GraphRAG 索引,即Indexing过程;

query

检索GraphRAG 的查询,即Querying过程;

update

更新GraphRAG 的索引,即增量更新;

07、GraphRAG 测试数据准备

华为：从通信设备到智能生态领导者

华为技术有限公司由任正非于1987年在中国深圳创立，起初专注于电信设备的制造。凭借持续的技术创新和对客户需求的敏锐洞察，华为逐渐成长为全球领先的ICT（信息与通信技术）解决方案提供商。20世纪初，华为开始涉足手机市场，并迅速推出了多款备受欢迎的智能手机，如Mate系列和P系列，这些产品不仅在设计上领先，更在影像技术和5G通讯能力方面树立了新的标杆。

近年来，华为加大了对基础研究的投入，致力于构建万物互联的智能世界。其推出的HarmonyOS操作系统、昇腾AI处理器以及鲲鹏计算平台，标志着华为正从单一的产品制造商向提供全面智能解决方案的服务商转型。此外，华为还在云计算、自动驾驶网络等领域取得了显著成就，成为推动行业智能化转型的重要力量。

小米：以性价比著称的科技新贵

小米科技有限责任公司成立于2010年，由雷军等八位联合创始人共同创办。小米以“为发烧而生”的理念迅速崛起，主打高性价比的智能手机和其他消费电子产品。首款小米手机一经推出便获得了市场的热烈反响，随后几年里，小米通过不断扩展产品线，包括智能家居设备、可穿戴设备及配件等，建立了庞大的生态系统。

除了硬件产品的成功外，小米还注重软件和服务的开发，MIUI操作系统便是其核心竞争力之一。近年来，小米进一步加强了对人工智能和物联网领域的投资，发布了小爱同学语音助手和米家App，旨在打造一个无缝连接的智能生活体验。随着小米汽车项目的推进，小米正逐步实现从互联网企业到多元化科技集团的转变。

阿里巴巴：电子商务与云服务的双重驱动

阿里巴巴集团成立于1999年，由马云和他的团队在中国杭州创立。作为一家集电子商务、零售、金融、物流等多元化业务于一体的大型互联网公司，阿里巴巴旗下拥有淘宝网、天猫商城等多个知名电商平台。自成立以来，阿里巴巴通过技术创新和服务优化，极大地促进了中国乃至全球电商市场的发展。

2009年，阿里巴巴推出了阿里云服务，开启了公司在云计算领域的探索之路。如今，阿里云已经成为仅次于亚马逊AWS的世界第二大公共云服务供应商。与此同时，阿里巴巴还积极探索大数据、人工智能等前沿技术的应用，力求为企业和社会创造更大的价值。通过一系列的战略布局，阿里巴巴不仅巩固了其在全球电商领域的领导地位，也为未来的数字化转型奠定了坚实的基础。

以上内容是对华为、小米和阿里巴巴三家公司发展历程的一个概述，展现了它们如何从各自领域起步，成长为影响全球科技行业的关键参与者。这些公司的故事反映了科技创新的力量及其对社会经济发展的深远影响。

08、GraphRAG 核心参数配置

核心步骤	操作
执行初始化命令	<pre>graphrag init --root ./</pre> 其中 --root 参数用于指定生成的配置文件的存储路径，./ 表示当前目录。 ● settings.yaml: 主配置文件，包含 GraphRAG 从索引构建到检索的设置； ● .env: 环境变量文件。里面主要存储的是API_KEY密钥等敏感信息，在settings.yaml文件中引用； ● prompts/: 提示词文件夹。它包含 GraphRAG 使用的默认提示；
修改.env参数	<pre>vi .env</pre> 填写.env文件中的GRAPHRA_API_KEY，这里我们使用DeepSeek的API_KEY，大家可以根据自己的需求选择不同的模型。
修改settings.yaml	<pre>vim settings.yaml</pre> 填写对应参数信息

参数	描述
api_base	请求某个模型调用 REST API 的 Endpoint 。
api_key	作为变量, 引用 .env 文件中的 GRAPHRA_API_KEY 。
encodeing_model	设置编码模型。
model	请求某个模型调用 REST API 对应的模型名称。

参数	描述
api_base	请求某个模型调用 REST API 的 Endpoint 。
api_key	有效的请求 API_KEY 。
encodeing_model	设置编码模型。
model	请求某个模型调用 REST API 对应的模型名称。

09、Microsoft GraphRAG 核心命令快速体验

核心步骤	操作命令
构建索引	<code>graphrag index --root ./</code>
内容查询	<code>graphrag query --root ./input --method global --query 文档里面涉及几家公司?</code>

10、Microsoft GraphRAG原理


去年技术团队的成果是什么？

李四去年的技术成果


技术一部去年的技术成果

技术部的技术成果

公司去年的成果




LLM



搭建知识图谱

社区挖掘



② GraphRAG 深度剖析之 Index 流程详解

01、Microsoft GraphRAG源码阅读环境构建

操作步骤	操作内容
1.下载源码	1. 可以直接到： https://github.com/microsoft/graphrag 手动下载 2. 也可以基于git下载： <code>git clone https://github.com/microsoft/graphrag.git</code>
2.构建环境	<code>conda create --name graph python=3.11</code> <code>conda activate graph</code>
3.安装依赖	Microsoft GraphRAG 项目依赖是通过poetry来管理的，因此我们需要先安装poetry。安装命令如下： <code>pip install poetry</code> 安装完poetry后，我们就可以使用poetry来安装Microsoft GraphRAG 项目依赖了。安装命令如下： <code>poetry install</code>
4.初始化配置文件	<code>poetry run poe init --root ./</code>
5.配置参数	跟之前一样
6.数据准备	跟之前一样
7.构建索引	<code>poetry run poe index --root ./</code>

02、GraphRAG 深度剖析之 Index 流程详解

参数名称	类型	描述
type	InputType	使用的输入类型。选项是 file 或 blob
file_type	InputFileType	指定使用的输入文件类型，目前只支持 csv 和 txt
base_dir	str	读取输入文件的根目录
connection_string	str	None
storage_account_blob_url	str	None
container_name	str	None
file_encoding	str	指定输入文件的编码
file_pattern	str	指定输入文件的模式
file_filter	dict[str, str]	None
text_column	str	指定使用的输入文本列，仅限 csv 文件类型使用
title_column	str	None
metadata	list[str]	None

02、GraphRAG 深度剖析之 Index 流程详解

字段名称	参数类型	描述
size	int	使用的块大小。
overlap	int	使用的块重叠量。
group_by_columns	list[str]	用于分块的列，默认是以 id 分组
strategy	ChunkStrategyType	使用的分块策略。
encoding_model	str	使用的编码模型。
prepend_metadata	bool	是否在每个块前添加元数据。
chunk_size_includes_metadata	bool	在最大令牌中是否计算元数据。

02、GraphRAG 深度剖析之 Index 流程详解

```
import nltk
from nltk.tokenize import sent_tokenize

# 下载 punkt 模型 (如果尚未下载)
nltk.download('punkt')

# 示例中文文本
text = "你好！你最近怎么样？这是一个句子分割的示例。让我们看看它是如何工作的。"

# 使用 sent_tokenize 进行句子分割
sentences = sent_tokenize(text, language='chinese')


# 输出分割后的句子
for sentence in sentences:
    print(sentence)
```

输出文本：

```
你好！
你最近怎么样？
这是一个句子分割的示例。
让我们看看它是如何工作的。
```

3 GraphRAG 深度剖析之 图数据库实操

03、GraphRAG 深度剖析之 图数据库实操




4 GraphRAG 深度剖析之 Query查询篇

01、Microsoft GraphRAG 核心命令快速体验

查询方式	操作命令
构建索引	<code>graphrag index --root ./</code>
local查询	本地搜索从相关实体开始，使用知识图谱来查找最相关的信息。例如，给定查询中的实体，使用的是连接节点的信息，通过辨识与查询相关的实体与关系，检索特定文本片段、摘要和关联性资料。 本质上是基于实体的推理。特别适合回答“who”、“what”、“when” 类型的问题。 <pre>graphrag query --root ./ --method local --query "华为都有哪些产品？"</pre>
global查询	全局搜索算法旨在回答需要了解整个数据集的抽象问题，即借助社区摘要来获取全局的答案。全局搜索更侧重于为需要更高层次理解的问题提供答案。比如文件中提到了哪些公司？这类问题。 <pre>graphrag query --root ./ --method global --query 知识库里面涉及几家公司？</pre>

02、Microsoft GraphRAG-Global查询原理



03、Microsoft GraphRAG-Local查询原理

