

企业智能客服

西瓜老师



目录

- | | | | |
|---|-----------|----|-----------|
| 1 | 智能客服之需求分析 | 6 | 智能客服之代码落地 |
| 2 | 智能客服之架构设计 | 7 | 智能客服之项目联调 |
| 3 | 智能客服之技术选型 | 8 | 智能客服之项目上线 |
| 4 | 智能客服之资源评估 | 9 | 智能客服之二期需求 |
| 5 | 智能客服之模型部署 | 10 | 智能客服之代码落地 |

1 智能客服之需求分析

01、智能客服之需求分析

二期：智能客服

通过智能问答，高效解答用户问题、提升服务体验并降低人工成本。

02

01

一期：智能助手

通过智能问答，为用户提供快速准确的信息查询和问题解答服务

03、智能客服之一期-需求分析

参考平台	地址
OpenAI的ChatGPT平台	https://chatgpt.com/
阿里巴巴的通义千问平台	https://tongyi.aliyun.com/qianwen
深度求索的DeepSeek平台	https://chat.deepseek.com/
月之暗面的Kimi平台	https://kimi.moonshot.cn/

02、智能客服之一期-需求分析



02、智能客服之一期-需求分析

新对话

什么是机器学习?



思考中...

嗯，用户问什么是机器学习，这看起来像是一个基本概念的问题。首先，我需要确定用户的基础知识水平。他们可能是个刚入门的学生，或者只是对这个领域感到好奇的普通人。接下来，我得考虑如何用简单易懂的语言解释，避免使用太多专业术语，或者在必要时解释清楚术语。

我应该从机器学习的核心概念入手，就是让计算机从数据中学习规律，而不是通过明确的编程指令。然后，可能需要区分传统编程和机器学习的区别，传统编程是输入规则和数据进行答案输出，而机器学习是输入数据和答案来让机器找出规则。

接下来，用户可能想知道机器学习的应用场景，比如推荐系统、图像识别等，这些例子能帮助他们更好地理解。然后，需要简要介绍机器学习的类型，比如监督学习、无监督学习、强化学习，这些分类能展示机器学习的多样性。

同时，我应该提到机器学习的基本流程，比如数据准备、模型选择、训练、评估和部署，这样用户能了解整个过程。还有可能用户对机器学习的挑战感兴趣，比如数据质量、过拟合等问题，这也是需要注意的部分。

给 DeepSeek 发送消息

深度思考 (R1) 联网搜索



内容由 AI 生成，请仔细甄别

新对话

要确保回答结构清晰，分点说明，但不要太刻板。可能需要用一些比喻，比如把训练模型比作教小孩识别动物，这样更形象。最后，检查是否有遗漏的重要点，比如常用算法或实际应用案例，是否需要进一步展开，但根据问题本身，可能不需要太深入，保持简明即可。

机器学习 (Machine Learning, ML) 是人工智能 (AI) 的一个子领域，其核心是让计算机系统通过从数据中**自动学习规律和模式**，从而完成特定任务，而无需依赖明确的编程指令。简单来说，机器学习的目标是让机器像人类一样通过“经验”（数据）来改进自身的性能。

关键概念

1. 数据驱动

机器学习模型不是通过人工编写规则，而是通过分析大量数据（如文本、图像、传感器数据等）自动发现规律。

2. 模型与算法

- 模型：从数据中学习到的规律（例如数学方程、神经网络结构）。
- 算法：用于训练模型的方法（如线性回归、决策树、深度学习）。

3. 训练与预测


给 DeepSeek 发送消息

深度思考 (R1) 联网搜索



内容由 AI 生成，请仔细甄别

03、智能客服之一期-需求分析



04、智能客服之一期-需求分析



验证码登录

密码登录

你所在地区仅支持 手机号 / 微信 / 邮箱 登录

+86 请输入手机号

请输入验证码

发送验证码

注册登录即代表已阅读并同意我们的 [用户协议](#) 与 [隐私政策](#)，未注册的手机号将自动注册


登录



 微信扫码登录

② 智能客服之架构设计

01、智能客服之架构设计




③ 智能客服之技术选型

01、智能客服之一期-技术选型



4 智能客服之资源评估

01、智能客服之一期-资源评估



02、智能客服之一期-资源评估

1. 模型参数单位

术语解释：

"10b"、"13b"、"70b"等表示模型参数数量，"b"代表"十亿"。

- 10b： 约100亿个参数
- 13b： 约130亿个参数
- 70b： 约700亿个参数

2. 数据类型及其内存占用：

- Float32 (32位)： 每个参数占用4字节，适用于高精度需求。
- Float16 (16位)： 每个参数占用2字节，适用于减少内存和加速计算。
- Float64 (64位)： 每个参数占用8字节，提供更高精度但占用更多内存。
- Int32/Int64： 分别占用4字节或8字节，通常用于表示离散数值。
- Int8/Int4 (量化)： Int8占用1字节，Int4通过位操作存储，适用于模型压缩和加速。

量化：用低精度的值去替代高精度的值

03、智能客服之一期-资源评估

deepseek-r1

DeepSeek's first-generation of reasoning models with comparable performance to OpenAI-o1, including six dense models distilled from DeepSeek-R1 based on Llama and Qwen.

1.5b 7b 8b 14b 32b 70b 671b

↓ 29.9M Pulls ⌚ Updated 6 weeks ago

32b



🔖 29 Tags

ollama run deepseek-r1:32b



Updated 2 months ago

38056bbcbb2d · 20GB

model

arch qwen2 · parameters 32.8B

quantization Q4_K_M

20GB

Q4_K_M量化并不是简单的全参数 4 位量化，而是一种混合量化策略，通过在关键张量上使用更高精度，以及存储附加参数，来在模型体积和精度之间取得平衡

04、智能客服之一期-资源评估



<https://www.muliao.com/>

随时有GPU资源

能使用Docker



<https://www.autodl.com/>

计费方式: ☒ 按量计费 ☐ 包日 ☐ 包周 ☐ 包月

选择地区: ☒ 内蒙B区 ☐ 重庆A区 ☐ 西北B区 ☐ 北京B区 ☐ 北京A区 ☐ 佛山区 ☐ 内蒙A区

☒ L20专区 ☐ 3090专区 ☐ V100专区 ☐ A800专区 ☐ 华为昇腾专区

GPU型号: ☐ 全部 ☐ vGPU-32GB (0/310) ☐ RTX 4090 (1/1544) ☐ RTX 3080x2 (0/357)

GPU数量: 1 2 3 4 5 6 7 8 10 12

功能成熟稳定

显卡类型多

5 智能客服之模型智商测试

01、智能客服之一期-模型智商测试

对话在线模型	思维链模型
DeepSeek-V3	DeepSeek-R1-Distill-Qwen-32B

看全球模型能力排行版

自己进行能力测试

用自己的私有数据进行测试




02、智能客服之一期-模型智商测试

全球顶级大模型排行版: <https://lmarena.ai/?leaderboard=>

Rank★ (UB)	Rank (StyleCtrl)	Model	Arena Score	95% CI	Votes	Organizati	License
1	1	Gemini-2.5-Pro-Exp-03-25	1443	+8/-13	2540	Google	Proprietar y
2	4	Grok-3-Preview-02-24	1404	+5/-6	10398	xAI	Proprietar y
2	2	GPT-4.5-Preview	1398	+7/-6	10615	OpenAI	Proprietar y
4	7	Gemini-2.0-Flash- Thinking-Exp-01-21	1381	+4/-3	22659	Google	Proprietar y
4	4	Gemini-2.0-Pro-Exp-02-05	1380	+5/-5	20293	Google	Proprietar y
4	3	ChatGPT-4o-latest (2025- 01-29)	1374	+5/-4	22517	OpenAI	Proprietar y
7	5	DeepSeek-R1	1360	+5/-5	12772	DeepSeek	MIT

03、智能客服之一期-模型测试

模型得分	问答及翻译能力	角色扮演	长文本编写	数学能力	编程能力	科研能力	逻辑推理（物理世界理解）
QwQ-32B	90.2	95.1	92.8	97.1	96.9	91.5	86.5
DeepSeek R1	92.6	93.9	95.4	97.6	97.4	94.2	96.1




04、智能客服之一期-模型智商测试

opencompass司南评测: <https://github.com/open-compass>

OpenCompass是一个一站式的大模型评估平台, 旨在为大模型评估提供一个公平、开放和可复制的基准。它不仅量化了模型在知识、语言、理解、推理等方面的能力, 还推动了模型的迭代和优化。

其主要特点包括:



05、智能客服之一期-模型智商测试

```
conda create --name opencompass python=3.10 -y
conda activate opencompass
```

```
# 支持绝大多数数据集及模型
pip install -U opencompass
```

```
git clone https://github.com/open-compass/opencompass opencompass
```

```
pip install modelscope
```

```
export DATASET_SOURCE=ModelScope
```

```
(mobile_agent_e2) ~/PycharmProjects/GitHub/MobileAgent/Mobile-Agent-E git:[main]
bash scripts/run_task.sh
Traceback (most recent call last):
  File "/Users/wufan/PycharmProjects/GitHub/MobileAgent/Mobile-Agent-E/run.py", line 2, in <module>
    from inference_agent_E import run_single_task
  File "/Users/wufan/PycharmProjects/GitHub/MobileAgent/Mobile-Agent-E/inference_agent_E.py", line 20, in <module>
    from modelscope.pipelines import pipeline
  File "/opt/anaconda3/envs/mobile_agent_e2/lib/python3.10/site-packages/modelscope/pipelines/_init_.py", line 4, in <module>
    from .base import Pipeline
  File "/opt/anaconda3/envs/mobile_agent_e2/lib/python3.10/site-packages/modelscope/pipelines/base.py", line 16, in <module>
    from modelscope.msdatasets import MsDataset
  File "/opt/anaconda3/envs/mobile_agent_e2/lib/python3.10/site-packages/modelscope/msdatasets/_init_.py", line 2, in <module>
    from modelscope.msdatasets.ms_dataset import MsDataset
  File "/opt/anaconda3/envs/mobile_agent_e2/lib/python3.10/site-packages/modelscope/msdatasets/ms_dataset.py", line 25, in <module>
    from modelscope.msdatasets.utils.hf_datasets_util import load_dataset_with_ctx
  File "/opt/anaconda3/envs/mobile_agent_e2/lib/python3.10/site-packages/modelscope/msdatasets/utils/hf_datasets_util.py", line 19, in <module>
    from datasets.data_files import (
ImportError: cannot import name 'get_metadata_patterns' from 'datasets.data_files' (/opt/anaconda3/envs/mobile_agent_e2/lib/python3.10/site-package
```

pip install "datasets<3"

06、智能客服之一期-模型智商测试

```
(opencompass) root@autodl-container-312e40a75b-5ad6ad0a: ~/autodl-tmp/opencompass# python tools/list_configs.py deepseek
```

Model	Config Path
hf_deepseek_67b_base	opencompass/configs/models/deepseek/hf_deepseek_67b_base.py
hf_deepseek_67b_chat	opencompass/configs/models/deepseek/hf_deepseek_67b_chat.py
hf_deepseek_7b_base	opencompass/configs/models/deepseek/hf_deepseek_7b_base.py
hf_deepseek_7b_chat	opencompass/configs/models/deepseek/hf_deepseek_7b_chat.py
hf_deepseek_coder_1_3b_instruct	opencompass/configs/models/deepseek/hf_deepseek_coder_1_3b_instruct.py
hf_deepseek_coder_33b_instruct	opencompass/configs/models/deepseek/hf_deepseek_coder_33b_instruct.py
hf_deepseek_coder_6_7b_instruct	opencompass/configs/models/deepseek/hf_deepseek_coder_6_7b_instruct.py

列出支持的DeepSeek的模型

```
(opencompass) root@autodl-container-312e40a75b-5ad6ad0a: ~/autodl-tmp/opencompass# python tools/list_configs.py gsm8k
```

Model	Config Path
hf_gsm8k_rft_llama7b2_ul3b	opencompass/configs/models/others/hf_gsm8k_rft_llama7b2_ul3b.py

Dataset	Config Path
demo_gsm8k_base_gen	opencompass/configs/datasets/demo/demo_gsm8k_base_gen.py
demo_gsm8k_chat_gen	opencompass/configs/datasets/demo/demo_gsm8k_chat_gen.py
deprecated_gsm8k_agent_gen_bel1606	opencompass/configs/datasets/gsm8k/deprecated_gsm8k_agent_gen_bel1606.py
gsm8k_0shot_gen_a58960	opencompass/configs/datasets/gsm8k/gsm8k_0shot_gen_a58960.py
gsm8k_0shot_nocot_gen_6cbf22	opencompass/configs/datasets/gsm8k/gsm8k_0shot_nocot_gen_6cbf22.py
gsm8k_0shot_v2_gen_17d799	opencompass/configs/datasets/gsm8k/gsm8k_0shot_v2_gen_17d799.py
gsm8k_0shot_v2_gen_6e39a4	opencompass/configs/datasets/gsm8k/gsm8k_0shot_v2_gen_6e39a4.py
gsm8k_0shot_v2_gen_a58960	opencompass/configs/datasets/gsm8k/gsm8k_0shot_v2_gen_a58960.py
gsm8k_agent_gen_c3dff3	opencompass/configs/datasets/gsm8k/gsm8k_agent_gen_c3dff3.py
gsm8k_contamination_ppl_ecdd22	opencompass/configs/datasets/gsm8k_contamination/gsm8k_contamination_ppl_ecdd22.py
gsm8k_gen	opencompass/configs/datasets/gsm8k/gsm8k_gen.py

列出gsm8k的数据集

07、智能客服之一期-模型智商测试

语言	知识	推理	考试
▼ 字词释义 • WiC • SummEdits ▼ 成语习语 • CHID ▼ 语义相似度 • AFQMC • BUSTM ▼ 指代消解 • CLUEWSC • WSC • WinoGrande ▼ 翻译 • Flores • IWSLT2017 ▼ 多语种问答 • TyDi-QA • XCOPA ▼ 多语种总结 • XLSum	▼ 知识问答 • BoolQ • CommonSenseQA • NaturalQuestions • TriviaQA	▼ 文本蕴含 • CMNLI • OCNLI • OCNLI_FC • AX-b • AX-g • CB • RTE • ANLI ▼ 常识推理 • StoryCloze • COPA • ReCoRD • HellaSwag • PIQA • SIQA ▼ 数学推理 • MATH • GSM8K ▼ 定理应用 • TheoremQA • StrategyQA • SciBench ▼ 综合推理 • BBH	▼ 初中/高中/大学/职业考试 • C-Eval • AGIEval • MMLU • GAOKAO-Bench • CMMLU • ARC • Xiezhi ▼ 医学考试 • CMB

理解	长文本	安全	代码
▼ 阅读理解 • C3 • CMRC • DRCD • MultiRC • RACE • DROP • OpenBookQA • SQuAD2.0 ▼ 内容总结 • CSL • LCSTS • XSum • SummScreen ▼ 内容分析 • EPRSTMT • LAMBADA • TNEWS	▼ 长文本理解 • LEval • LongBench • GovReports • NarrativeQA • Qasper	▼ 安全 • CivilComments • CrowsPairs • CValues • JigsawMultilingual • TruthfulQA ▼ 健壮性 • AdvGLUE	▼ 代码 • HumanEval • HumanEvalX • MBPP • APPs • DS1000

```
python run.py --datasets demo_gsm8k_chat_gen --models hf_deepseek_r1_distill_qwen_7b
```

08、智能客服之一期-模型智商测试

```
python run.py --datasets ceval_gen --models hf_chatglm2_6b
```


- gen 数据集（生成式评测）**
用于评估模型在**开放式生成任务**中的表现，例如数学解题、代码生成、自由问答等。这类任务要求模型直接生成完整答案文本，评测时需比对生成内容与标准答案的匹配度 8 11。
适用场景：对话模型（如ChatGPT）或经过指令微调的基座模型，需输出结构化答案的任务 4 7。
- pp1 数据集（判别式评测）**
基于**困惑度（Perplexity）**计算，评估模型对候选答案的辨别能力。通过将问题与多个候选答案组合，计算模型对每个组合的困惑度，选择最低困惑度的答案作为预测结果 8 11。
适用场景：未经微调的基座模型（如LLaMA、GPT-3），适用于选择题或判断题等封闭式任务 7 9。

维度	gen 数据集	pp1 数据集
评测任务	生成类（数学、代码、翻译）	判别类（选择、判断、填空）
答案自由度	高，需处理自由文本	低，依赖预设候选答案
计算复杂度	高，需生成完整响应	低，仅计算困惑度
后处理需求	需清洗和匹配答案	无，直接选择困惑度最低答案
适用模型	对话模型、指令微调模型	基座模型

小作业：对比一下QwQ-32B和DeepSeek-R1-Distill-Qwen-32B的能力

⑥ 智能客服之模型部署

01、智能客服之一期-模型部署



02、智能客服之一期-模型部署-Ollama平台介绍

Ollama是在Github上的一个开源项目，其项目定位是：一个本地运行大模型的集成框架，目前主要针对主流的LLaMA架构的开源大模型设计，通过将模型权重、配置文件和必要数据封装进由Modelfile定义的包中，从而实现大模型的下载、启动和本地运行的自动化部署及推理流程。此外，Ollama内置了一系列针对大模型运行和推理的优化策略，目前作为一个非常热门的大模型托管平台，基本主流的大模型应用开发框架如LangChain、AutoGen、Microsoft GraphRAG及热门项目AnythingLLM、OpenWebUI等高度集成。

它帮助用户快速在本地运行大模型。通过简单的安装指令，用户可以执行一条命令就在本地运行开源大型语言模型，如Llama 2。Ollama极大地简化了在Docker容器内部署和管理LLM的过程，使得用户能够快速地在本地运行大型语言模型。



Get up and running with large
language models.

地址：<https://ollama.com/>

03、智能客服之一期-模型部署-网络参数配置

Download Ollama



Install with one command:

```
curl -fsSL https://ollama.com/install.sh | sh
```

[View script source](#) • [Manual install instructions](#)

```
curl -fsSL https://ollama.com/install.sh | sh
```

修改参数: `vi /etc/systemd/system/ollama.service`
重启服务: `systemctl daemon-reload`
`systemctl restart ollama`

参数	作用
OLLAMA_HOST	定义 Ollama 服务器的协议和主机地址。默认为 127.0.0.1:11434，仅本机地址可通过 11434 端口访问该服务。可以通过此变量自定义 Ollama 服务的监听地址和端口，例如设置为 0.0.0.0:8080，可允许其他电脑访问 Ollama（如：局域网中的其他电脑）。默认使用 http 协议。若要使用 https 协议，可设置为： https://0.0.0.0:443 Environment="OLLAMA_HOST=0.0.0.0:11434"

04、智能客服之一期-模型部署-模型参数配置

参数	作用
OLLAMA_MODELS	指定模型文件的存储路径。默认为用户主目录下的 .ollama/models 文件夹。通过设置此变量，可以自定义模型文件的存储位置，例如 OLLAMA_MODELS=/path/to/models 将模型存储在指定的路径下。
OLLAMA_KEEP_ALIVE	控制模型在内存中的存活时间。默认为 5 分钟。负值表示无限存活，0 表示不保持模型在内存中。此变量用于优化模型加载和运行的性能，例如 OLLAMA_KEEP_ALIVE=30m 可以让模型在内存中保持 30 分钟。
OLLAMA_LOAD_TIMEOUT	设置模型加载过程中的超时时间。默认为 5 分钟。0 或负值表示无限超时。此变量用于防止模型加载过程过长导致服务无响应，例如 OLLAMA_LOAD_TIMEOUT=10m 可以将超时时间设置为 10 分钟。
OLLAMA_MAX_LOADED_MODELS	限制同时加载的模型数量。默认为 0，表示不限制。此变量用于合理分配系统资源，避免过多模型同时加载导致资源不足，例如 OLLAMA_MAX_LOADED_MODELS=4 可以限制同时加载 4 个模型。
OLLAMA_MAX_QUEUE	设置请求队列的最大长度。默认为 512。此变量用于控制并发请求的数量，避免过多请求同时处理导致服务过载，例如 OLLAMA_MAX_QUEUE=1024 可以将队列长度设置为 1024。
OLLAMA_MAX_VRAM	设置 GPU 显存的最大使用量（以字节为单位）。默认为 0，表示不限制。此变量用于控制 GPU 资源的使用，避免显存不足导致的问题，例如 OLLAMA_MAX_VRAM=8589934592 可以将显存限制为 8GB。

重启服务：systemctl daemon-reload, systemctl restart ollama

05、智能客服之一期-模型部署-性能参数配置

使用最简单的命令，即ollama run xxxx时，Ollama的内部机制会根据启动模型的参数量去运行该模型所需的VRAM(显存)。如果该模型可以使用单个GPU加载，则Ollama将在该GPU上加载该模型。这种做法一般可以提供出最佳的性能，因为它可以减少推理过程中PCI总线的数据传输量。而如果该模型没办法仅在一个GPU上加载，则将分布在所有可用的GPU中。

如果想加载多张显卡且做到负载均衡，可以去修改 ollama 的SystemD配置服务，操作流程如下：

操作步骤	执行动作
(1) 进入编辑环境	<code>vi /etc/systemd/system/ollama.service</code>
(2) 修改配置文件	<code>Environment="CUDA_VISIBLE_DEVICES=0,1,2"</code> <code>Environment="OLLAMA_SCHED_SPREAD=1" # 这个参数是做负载均衡</code>
(3) 重启ollama服务	<code>systemctl daemon-reload</code> <code>systemctl restart ollama</code>

06、智能客服之一期-模型部署-负载均衡效果

```
(py38) root@vmInstancekxot7ile:~# nvidia-smi
Fri Mar 28 04:39:23 2025
```

NVIDIA-SMI 560.35.03			Driver Version: 560.35.03			CUDA Version: 12.6		
GPU Fan	Name Temp	Perf	Persistence-M Pwr:Usage/Cap	Bus-Id	Disp.A Memory-Usage	Volatile GPU-Util	Uncorr. Compute M.	ECC MIG M.
0 30%	NVIDIA GeForce RTX 4090 30C	P0	69W / 450W	00000000:00:06.0	Off 21650MiB / 24564MiB	0%	Default	Off N/A
1 30%	NVIDIA GeForce RTX 4090 27C	P8	22W / 450W	00000000:00:07.0	Off 4MiB / 24564MiB	0%	Default	Off N/A

Processes:							GPU Memory Usage
GPU	GI ID	CI ID	PID	Type	Process name		
0	N/A	N/A	6312	C	/usr/local/bin/ollama		21640MiB

```
(py38) root@vmInstancekxot7ile:~# nvidia-smi
Fri Mar 28 04:44:40 2025
```

NVIDIA-SMI 560.35.03			Driver Version: 560.35.03			CUDA Version: 12.6		
GPU Fan	Name Temp	Perf	Persistence-M Pwr:Usage/Cap	Bus-Id	Disp.A Memory-Usage	Volatile GPU-Util	Uncorr. Compute M.	ECC MIG M.
0 30%	NVIDIA GeForce RTX 4090 31C	P0	70W / 450W	00000000:00:06.0	Off 11448MiB / 24564MiB	0%	Default	Off N/A
1 30%	NVIDIA GeForce RTX 4090 29C	P5	68W / 450W	00000000:00:07.0	Off 11470MiB / 24564MiB	0%	Default	Off N/A

Processes:							GPU Memory Usage
GPU	GI ID	CI ID	PID	Type	Process name		
0	N/A	N/A	6533	C	/usr/local/bin/ollama		11438MiB
1	N/A	N/A	6533	C	/usr/local/bin/ollama		11460MiB

07、智能客服之一期-模型部署-常用命令

命令	用途
<code>ollama serve</code>	在本地系统上启动 Ollama。
<code>ollama create <new_model></code>	从现有模型创建一个新模型，用于定制或训练。
<code>ollama show <model></code>	显示特定模型的详细信息，例如其配置和发布日期。
<code>ollama run <model></code>	运行指定的模型，使其准备好进行交互。
<code>ollama pull <model></code>	将指定的模型下载到您的系统。
<code>ollama list</code>	列出所有已下载的模式。
<code>ollama ps</code>	显示当前正在运行的模型。
<code>ollama stop <model></code>	停止指定的正在运行的模型。
<code>ollama rm <model></code>	从您的系统中移除指定的模型。

7 智能客服之模型压力测试

01、模型压力测试

模型智商测试


模型并发测试



7 智能客服之智能助手开发

⑧ 智能客服之智能客服整体架构设计

01、企业级智能客服之落地方案




02、企业级智能客服之关键技术选型

Agent实现: LangGraph

RAG实现: Microsoft GraphRAG

02、企业级智能客服之技术选型



Swarm: 比CrewAI更轻量级, 简洁, 适合配合顶级在线大模型。配合开源模型效果不好。

CrewAI: 比LangGraph轻量级, 代码更简洁, 可上生产。封装得比较厉害, 中间很多过程不可控。

LangGraph: LangChain团队发布的, 偏底层, 更灵活, 扩展性好, 推荐生产中使用。学习曲线高。

03、企业级智能客服之技术选型

LangChain

Chain: 链条



prompt | LLM1 | output | LLM2 |




有向无环图



适合面向过程式任务


LangGraph

Graph: 图



适合Agent循环迭代执行的任务

04、企业级智能客服之技术选型



1. 是一个存储信息的方法

2. 描述的是事实

3. 核心表达是实体和关系

4. 可以有多种实体，多种关系

05、企业级智能客服之技术选型


去年技术团队的项目成果是什么？

李四去年的技术成果


技术一部去年的技术成果

技术部的技术成果

公司去年的成果




LLM



搭建知识图谱

社区挖掘



06、企业级智能客服之技术选型

智能客服数据架构设计

